

UFOP - Universidade Federal de Ouro Preto

Decom - Departamento de Ciência da Computação

Modelos Básicos para IPMSMs

Autor: Bianca Barreto Leme

Matrícula: 24.1.4008

Professor: Rodrigo César Pedrosa Silva

Ouro Preto - MG
4 de setembro de 2025

Sumário

1	Introdução	2
2	Fundamentos	2
2.1	Motores analisados	2
2.1.1	2D	2
2.1.2	Nabla	2
2.1.3	V	2
2.2	Bases de dados	2
2.3	Métricas de Avaliação de Modelos de Regressão	3
2.3.1	Mean Absolute Percentage Error (MAPE)	3
2.3.2	Mean Squared Error (MSE)	3
2.3.3	Coefficiente de Determinação (R^2)	3
2.4	Modelos Utilizados	3
2.4.1	Regressão Linear	3
2.4.2	Árvores de Regressão	3
2.4.3	Random Forests	3
2.4.4	XGboos	3
2.4.5	CatBoost	3
3	Metodologia	3
3.1	Experimento 1: Identificar os Modelos mais Promissores	4
3.2	Experimento 2: Identificar o melhor conjunto de hiper parâmetros para os modelos mais promissores	4
4	Resultados	4
5	Conclusão	4

1 Introdução

Os Motores Síncronos de Ímã Interno Permanente (IPMSMs) têm sido amplamente utilizados por serem uma alternativa menos agressiva ao meio ambiente, quando comparados aos motores de carros comuns.

Em fase de testes (Finite Element Analysis), os motores devem ser submetidos a várias condições de velocidade e torque. Fazer estes testes fisicamente é custoso e pode levar dias. Por essa razão, utilizar “motores virtuais” e prever suas perdas através de modelos de IA pode ser muito mais viável, pois este método não tem grandes custos e levam por volta de algumas horas.

Estudando IPMSMs podemos criar modelos de inteligência artificial que nos auxiliem a prever as principais causas de perdas em ferro de determinado motor: perda por histerese e perda por eddy current.

Nesse contexto, este estudo tem como objetivo principal encontrar o melhor modelo de IA possível para prever as perdas em histerese e eddy current de 3 motores IPMSMs analisados: 2D, Nabla e V.

2 Fundamentos

2.1 Motores analisados

Neste trabalho, foram analisados 3 IPMSMs distintos:

2.1.1 2D

2.1.2 Nabla

2.1.3 V

2.2 Bases de dados

Os datasets analisados de cada motor fornecem os seguintes parâmetros:

- Variáveis geométricas;
- Speed;
- Id;
- Iq;
- Perda por histerese;
- Perda por eddy current.

Não entendo esses parâmetros.

2.3 Métricas de Avaliação de Modelos de Regressão

Para a análise da eficácia de cada modelo na predição dos atributos, foram definidas três métricas...

2.3.1 Mean Absolute Percentage Error (MAPE)

O *Mean Absolute Percentage Error* (MAPE) mede o erro percentual médio entre os valores reais y_i e os valores previstos \hat{y}_i :

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

2.3.2 Mean Squared Error (MSE)

O *Mean Squared Error* (MSE) mede o erro quadrático médio, penalizando mais fortemente desvios grandes:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

2.3.3 Coeficiente de Determinação (R^2)

O coeficiente de determinação, ou R^2 , mede a proporção da variância dos dados reais que é explicada pelo modelo:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

onde \bar{y} é a média dos valores reais.

2.4 Modelos Utilizados

Nesta seção, serão apresentados os diferentes modelos de aprendizado de máquina utilizados para a predição.

2.4.1 Regressão Linear

2.4.2 Árvores de Regressão

2.4.3 Random Forests

2.4.4 XGboos

2.4.5 CatBoost

3 Metodologia

Para atingir os objetivos deste trabalho, foram definidos 2 experimentos...

3.1 Experimento 1: Identificar os Modelos mais Promissores

3.2 Experimento 2: Identificar o melhor conjunto de hiper parâmetros para os modelos mais promissores

4 Resultados

Apresente os resultados obtidos (tabelas, gráficos, análises). Interprete os dados de forma clara e objetiva.

5 Conclusão

Retome os objetivos e destaque os principais achados. Comente limitações e sugestões para trabalhos futuros.